

Yol Hasarı ve Çukur Tespit Proje Raporu

Samet Mustafa Ceylan (23430070036)

Harun Batur (23430070014)

1. Proje Başlığı

YOLO11s Derin Öğrenme Modeli ile Akıllı Yol Hasarı ve Çukur Tespit Sistemi

Bu proje, yollardaki güvenliği tehdit eden hasarları (çukur, çatlak) ve yol elemanlarını (rögar kapağı) araç içi kameralar veya mobil cihazlardan alınan görüntüler üzerinden gerçek zamanlı olarak tespit etmeyi amaçlar. Derin öğrenme tabanlı nesne tespiti mimarilerinden YOLO11s (Small) modeli kullanılarak, yol altyapısının otomatik denetlenmesini sağlayan yapay zeka destekli bir karar destek sistemi geliştirilmiştir.

2. Projenin Amacı

Karayolu altyapısında oluşan deformasyonların zamanında taranıp onarılması, trafik güvenliğinin sağlanması ve araçların mekanik hasarlarının önlenmesi için kritik önem taşır. Geleneksel yöntemler el ile denetime veya vatandaş ihbarlarına dayandığı için yavaş, yüksek maliyetli ve systemsizdir. Bu projenin amacı, yapay zeka ve derin öğrenme teknikleri ile yol yüzeyindeki çukur (pothole), çatlak (crack) ve rögar kapağı (manhole) konumlarını görüntülerden otomatik ve yüksek doğrulukla tespit ederek belediyelerin ve karayolları bakım ekiplerinin iş süreçlerini otomatikleştirecek bir prototip sunmaktır.

3. Kullanılan Veri Seti

Projede, karayolu hasar tespiti için açık kaynaklı iki veri seti birleştirilerek kullanılmıştır. Birinci veri seti olan *Potholes-Detection-YOLOv8* (Kaggle - anggadwisunarto) 1.977 görüntüde çukur sınıfı içermektedir. İkinci veri seti olan *Road Damage Dataset — Potholes, Cracks and Manholes* (Kaggle - lorenzoarcioni) ise GoPro HERO7 ve Samsung Galaxy A14 kameralarıyla Roma ve Sacrofano (İtalya) sokaklarından toplanmış 2.000'den fazla görüntüde çukur, çatlak ve rögar sınıflarını barındırır. Sınıf yapısı ve anlamları aşağıdaki gibidir:

Sınıf ID	Sınıf Adı	Türkçe Anlamı	Açıklama
0	pothole	Çukur	Yol yüzeyinde aşınma ve darbe sonucu oluşan derin delikler.
1	crack	Çatlak	Asfalt üzerinde oluşan boyuna, enine veya timsah sırtı yarıklar.
2	manhole	Rögar Kapağı	Yol seviyesinde konumlanmış metal/beton kanalizasyon kapakları.

4. Veri Toplama ve Etiketleme

Kullanılan veri setlerindeki görüntüler, araç ön camına monte edilmiş kameralar ve akıllı telefonlar vasıtasıyla gerçek sürüş koşullarında kaydedilmiştir. Görüntüler farklı hava durumları, gün ışığı açıları, gölgeler ve asfalt türleri altında kaydedilerek çeşitlilik sağlanmıştır. Veri seti hazır etiketli olduğundan manuel etiketleme yapılmamıştır. Etiketler YOLO standardına uygun olarak normalize edilmiş sınırlayıcı kutu koordinatları (sınıf ID, merkez X, merkez Y, genişlik W, yükseklik H) şeklinde .txt dosyalarında saklanmaktadır.

5. Veri Bölme

Geliştirilen sistemin genelleme başarısını tarafsız bir şekilde ölçebilmek amacıyla birleşik veri seti rastgele olarak %80 eğitim ve %20 doğrulama (validation) setine bölünmüştür. Veri bölme sayıları şu şekildedir:

Kullanım Amacı	Görüntü Sayısı	Açıklama / Detay
Eğitim (Train)	3.181	Modelin ağırlıklarını güncellemek ve öznelikleri öğrenmek için kullanılır.
Doğrulama (Val)	796	Eğitim esnasında aşırı öğrenmeyi denetlemek ve performansı izlemek içindir.
Toplam	3.977	Kapsamlı yol analizi için kullanılan birleşik toplam veri.

Dosya adlarındaki olası çakışmaları önlemek için veri setlerinden gelen dosyalara sırasıyla ds1_ ve ds2_ ön ekleri (prefixes) eklenmiştir.

6. Kullanılan Model

Projede Ultralytics'in en güncel nesne tespiti mimarilerinden biri olan **YOLO11s (Small)** kullanılmıştır. YOLO11s, önceki nesil YOLOv8'e kıyasla daha az parametre ile daha yüksek doğruluk ve hızlı çıkarım sağlayan yeni C3k2 omurga katmanlarına ve gelişmiş dikkat (attention) mekanizmalarına sahiptir. Proje klasöründeki temel dosyalar ve görevleri şöyledir:

Dosya / Dizin	Açıklama ve Görevi
yolov11s-on-road-damage-dataset.ipynb	Kaggle GPU ortamında eğitimi ve değerlendirmeyi yürüten Jupyter Notebook.
best.pt	150 epoch eğitim sonunda doğrulama setinde en yüksek mAP değerini alan PyTorch model dosyası.
best.onnx	Edge ve web tarayıcı entegrasyonu için optimize edilerek dışa aktarılmış ONNX model dosyası.
app.py	Kullanıcıların fotoğraf yükleyip analiz yapabilmesi için yazılan Streamlit web uygulaması.
generate_report.py	Bu HTML ve PDF raporunu otomatik derleyen ve görselleri ölçekleyen Python betiği.
yolo11s_results/	Eğitim ve doğrulama esnasında üretilen kayıp grafiklerini, matrisleri ve ağırlıkları içeren klasör.

7. Eğitim Ayarları

Eğitim işlemi Kaggle platformunda Tesla T4 / P100 GPU donanımı üzerinde yürütülmüştür. Optimum yakınsama ve doğruluk elde etmek amacıyla `args.yaml` dosyasında tanımlanan hiperparametreler şöyledir:

Hiperparametre / Ayar	Değer	Açıklama
Maksimum Epoch	150	Eğitimin tamamlanacağı maksimum tur sayısı.
Batch Size	16	GPU bellek limitleri doğrultusunda seçilen yığın boyutu.
Görüntü Çözünürlüğü	640 x 640	Modele giren resimlerin yeniden boyutlandırılma ölçüsü.
Optimizasyon Algoritması	RAAdam	Daha kararlı öğrenme adımları sunan Rectified Adam.
Başlangıç Öğrenme Oranı (lr0)	0.00761	Eğitimin başlangıcındaki öğrenme hızı katsayısı.
Son Öğrenme Oranı Çarpanı (lrf)	0.06982	Cosine annealing ile lr nin düşeceği dip limit çarpanı.
Weight Decay (Ağırlık Aşınımı)	0.00715	Overfitting'i önlemek için uygulanan L2 düzenleme katsayısı.
Patience (Sabır Değeri)	10	Doğrulama kaybı 10 epoch iyileşmezse eğitimi sonlandırır.
Veri Artırma (Mosaic / fliplr)	1.0 / 0.5	Mozaikleme oranı 1.0 ve yatay aynalama olasılığı %50'dir.

8. Değerlendirme Sonuçları

Trained model, eğitimde hiç görülmemiş 796 doğrulama görüntüsü ile test edilmiş ve elde edilen performans değerleri yan yana karşılaştırmalı olarak sunulmuştur:


Metrik	Sonuç
mAP@0.5	0.5650
mAP@0.5:0.95	0.2700
Precision	0.5524
Recall	0.5348
F1-Score	0.5400

Sınıf	mAP@0.5	Anotasyon (Val)
pothole	0.5090	1.261
crack	0.3700	2.519
manhole	0.8160	1.310
Ortalama	0.5650	5.090

mAP Kullanımı Hakkında: Bu proje nesne tespiti (object detection) tabanlıdır. Bounding box tabanlı tespitlerde, konumlandırma ve sınıflandırma başarısını bir arada ölçen **mAP (mean Average Precision)** metriği temel alınmıştır.

9. Eğitim Grafikleri


150 epoch süresince kaydedilen eğitim ve doğrulama kayıp (loss) değerleri ile mAP eğrilerinin değişimi Şekil 1'de sunulmuştur:




Şekil 1: Eğitim ve Doğrulama Sürecindeki Kayıpların ve mAP Metriklerinin Değişimi (results.png)

10. Confusion Matrix

Modelin sınıfları ayırt etme başarısını ve hata eğilimlerini analiz etmek amacıyla Confusion Matrix (Karışıklık Matrisi) ve Precision-Recall (PR) eğrileri üretilmiştir:



Şekil 2: Karışıklık Matrisi (confusion_matrix.png)



Şekil 3: Sınıf Bazlı Precision-Recall Eğrisi (BoxPR_curve.png)

Matris incelendiğinde, çatlakların (crack) asfalttaki yama çizgileri veya gölgeler gibi arka plan yapılarıyla sıkça karıştırıldığı görülür. Bu durum çatlak sınıfındaki mAP başarısının neden daha düşük (0.370) olduğunu açıklamaktadır. Rögar kapakları ise belirgin geometrik şekilleri sayesinde yüksek başarımlı oranın (%81.6) yakalamıştır.

11. Sistem Nasıl Çalışır?

Geliştirilen Yol Hasarı ve Çukur Tespit Sistemi şu adımları takip ederek çalışır:

1. Kullanıcı Streamlit arayüzü üzerinden bir yol fotoğrafı yükler.
2. Sistem, yüklenen resmi YOLO modelinin giriş çözünürlüğü olan 640x640 boyutuna ölçekler.
3. Eğitilmiş YOLO11s modeli öznitelikleri çıkarır ve tek bir ileri besleme döngüsünde (one-pass) çukur, çatlak ve rögarları tespit eder.
4. Belirlenen güven eşiği (default 0.25) üzerindeki nesneler sınır kutularıyla işaretlenir ve sınıfları yazılır.
5. Arayüzde hasar türleri ve tespit adetleri istatistiksel olarak raporlanır.

12. Yol Hasarlarının Sınıflandırılması ve Anlamları

Yol yüzeyindeki hasarlar sürüş güvenliği ve yol bakımı açısından farklı önem derecelerine sahiptir:

- **pothole (Çukur):** Asfaltın derinlemesine aşınmasıyla oluşan çöküntülerdir. Araçların süspansiyonuna zarar verir ve motosikletler için hayati risk oluşturur. Acil müdahale seviyesindedir.
- **crack (Çatlak):** Su sızıntılarına neden olarak kış aylarında donma etkisiyle çukurlara dönüşen yüzeysel yarılmalardır. Önleyici bakım ile kapatılmalıdır.
- **manhole (Rögar Kapağı):** Yol seviyesinde konumlanmış metal/beton altyapı kapaklarıdır. Asfaltın çökmesi kaza riski oluşturur. Konum tespiti belediyeler için önem arz eder.

13. Hasar Tespiti ve Konumlandırma Nasıl Yapılır?

YOLO11s nesne tespiti mimarisi, anchor-free tasarımı sayesinde doğrudan sınır kutusu koordinatlarını regresyon yoluyla tahmin eder. Giriş resmi omurgada (C3k2) işlendikten sonra, decoupled head yapısı sayesinde sınıf tahmini (Classification) ve konumlandırma (Bounding Box Regression) işlemleri iki ayrı kolda gerçekleştirilir. Konumlandırma kaybı olarak **CloU Loss**, sınıflandırma kaybı olarak ise **BCE Loss** kullanılarak modelin koordinat doğruluğu optimize edilir.

14. Dijital Görüntü Çözümleme ile İlgisi

Proje, Dijital Görüntü Çözümleme dersinin temel teorik konularını pratik uygulamaya dönüştürmektedir:

- **Görüntü Yeniden Boyutlandırma:** Görüntülerin modele girmeden bilinear/bicubic yöntemlerle 640x640 çözünürlüğe ölçeklenmesi.
- **Renk Uzayı Manipülasyonları:** Modelin gün ışığı ve gölgede dayanıklı olmasını sağlamak için HSV uzayında rastgele değer (V) ve doygunluk (S) değişimlerinin uygulanması.
- **Evrişim (Convolution) Operasyonları:** Derin öğrenme katmanlarında kullanılan 3x3 ve 1x1 evrişimsel filtreler vasıtasıyla kenar, köşe ve yol doku detaylarının çıkarılması.
- **Piksel Normalizasyonu:** 0-255 arasındaki RGB piksel değerlerinin modele verilmeden önce [0, 1] aralığına normalize edilmesi.

15. Çıkarım (Inference)

Doğrulama setindeki yol fotoğrafları üzerinde yapılan test tahminleri ve gerçek etiketler (val_batch0 ve val_batch1) yan yana gösterilerek modelin başarısı görselleştirilmiştir:



Şekil 4: Doğrulama Grubu 0 - Gerçek Etiketler (Ground Truth)



Şekil 5: Doğrulama Grubu 0 - Model Tahmin Çıktıları



Şekil 6: Doğrulama Grubu 1 - Gerçek Etiketler (Ground Truth)



Şekil 7: Doğrulama Grubu 1 - Model Tahmin Çıktıları

16. Sonuç

Bu çalışma kapsamında, en güncel nesne tespiti modellerinden YOLO11s (Small) karayolu deformasyonlarını otomatik tespit etmek amacıyla başarıyla eğitilmiştir. Model, doğrulama setinde **0.565 mAP@0.5** genel doğruluğuna ulaşmıştır. Sınıf bazlı incelendiğinde rögarlarda %81.6 gibi yüksek bir başarı elde edilirken, çukurlar için %50.9 ve çatlaklar için %37.0 değerlerine ulaşılmıştır. Model web tabanlı Streamlit dashboard'a başarıyla bağlanmış ve ONNX formatına aktararak platformlar arası çalışabilecek hale getirilmiştir.